DATA office

PÔLE INNOVATION OPÉRATIONS

Etat de l'art HBase chez Arkéa

Date: 24/11/2025

Participants

Présents

NOM Prénom	Service	Fonction
LAURENT MORIN	Data Office	Architecte
GILDAS HOUMARD	DEXT	PM
ADRIEN GARNIER	BI&Analytics	RA
FLORIAN CARIOU	Data Office	RA
JORDAN MAHEU	MOE CAV EPARGNE	RA

Diffusion

NOM Prénom	Service	Mail
CRYSTAL Mark-Anthony	IBM	mark.crystal@ibm.com
LECONTE David	IBM	david.leconte1@ibm.com
GUTTILLA Pierre Louis	IBM	plguttilla@fr.ibm.com

Problématiques / Objectifs

Dans le cadre des futurs évolutions de la plateforme Bigdata interne Arkéa, le volet HBase est

un point critique. Ce moteur sert aujourd'hui des usages opérationnels importants du groupe que nous allons recenser et préciser dans ce document.

L'objectif est ici d'identifier précisément toutes les utilisations spécifiques de ce moteur afin de pouvoir qualifier un potentiel remplaçant.

Les projets concernés sont :

- Domirama
- Catégorisation des opérations
- Base d'Interaction Client
- Environnement de Données Marketing

Infrastructure

Arkéa a fait le choix de déployer l'infrastructure Hbase dans sa version Hadoop c'est-à-dire avec le service de stockage HDFS.

Software

HBase 1.1.2 sur Hadoop HDP 2.6.4

Software Attributes

Attribute Name	Value	Description
HBase Version	1.1.2.2.6.4.0-91, revision=2a88e694af7238290a5747f963a4fa0079c55bf9	HBase version and revision
HBase Compiled	Thu Jan 4 10:42:39 UTC 2018, jenkins	When HBase version was compiled and by whom
HBase Source Checksum	a3bd627e46a9a94cd352d7e907100bb5	HBase source MD5 checksum
Hadoop Version	2.7.3.2.6.4.0-91, revision=a4b6e1c0e98b4488d38bcc0a241dcbe3538b1c4d	Hadoop version and revision
Hadoop Compiled	2018-01-04T10:41Z, jenkins	When Hadoop version was compiled and by whom
Hadoop Source Checksum	9c28f884302610b59b221c7fbaeac3e	Hadoop source MD5 checksum
ZooKeeper Client Version	3.4.6-91, revision=-1	ZooKeeper client version and revision
ZooKeeper Client Compiled	01/04/2018 10:34 GMT	When ZooKeeper client version was compiled
Zookeeper Quorum	10.217.0.63:2182 10.217.0.31:2182	Addresses of all registered ZK servers. For more, see zk dump.
Zookeeper Base Path	/zk/hadoop/hbase-domirama	Root node of this cluster in ZK.
HBase Root Directory	hdfs://ha-manny/hdfs/hadoop/hbase-domirama	Location of HBase home directory

Hardware

Hors production à date : 1 instance Hbase mutualisée

En production à date : **2 instances HBase sur un même cluster Hadoop**

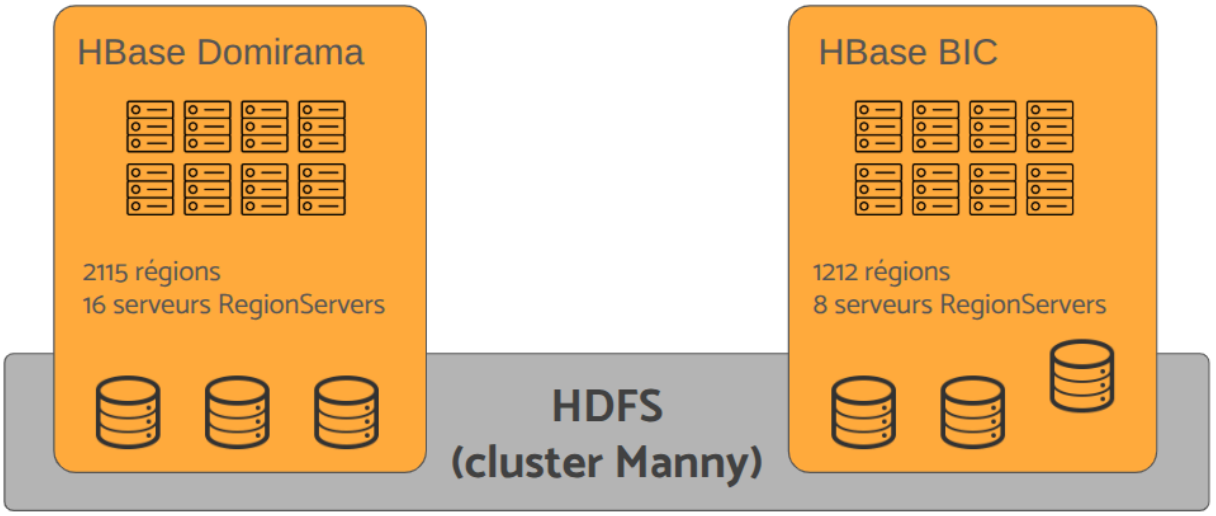

Les Noeuds hbase sont des machines physiques du cluster hadoop avec uniquement les rôles:

- **DataNode HDFS :** Localité des hfiles, Facteur de réplication x3, Rebalancing des hfiles en cas de panne
- **RegionServeur :** Service temps réel distribué lecture/écriture

HBase: DOMIRAMA

Requêtes par sec: ~4000 q/s

ServerName
jb-g11-04.p.infra.arkea.com,16020,1745739864466
jb-i11-07.p.infra.arkea.com,16020,1745739865735
jb-j07-20.p.infra.arkea.com,16020,1745739867244
jb-j11-06.p.infra.arkea.com,16020,1745739868544
jb-j11-08.p.infra.arkea.com,16020,1759139017420
jb-k07-17.p.infra.arkea.com,16020,1745739871289
jb-k20-11.p.infra.arkea.com,16020,1745739872706
jb-m07-24.p.infra.arkea.com,16020,1745739875041
va-g11-17.p.infra.arkea.com,16020,1745739875652
va-i11-06.p.infra.arkea.com,16020,1745739876793
va-i11-07.p.infra.arkea.com,16020,1745739878209
va-i50-19.p.infra.arkea.com,16020,1745739879510
va-j11-15.p.infra.arkea.com,16020,1745739880778
va-k07-17.p.infra.arkea.com,16020,1745739882601
va-k20-11.p.infra.arkea.com,16020,1745739883753
va-n20-31.p.infra.arkea.com,16020,1745739884963

16x Serveurs

Used Heap	Max Heap	Memstore Size
7.9 GB	15.1 GB	9 MB
13.2 GB	15.1 GB	0 B
6.4 GB	15.1 GB	14 MB
6.9 GB	15.1 GB	0 B
6.8 GB	15.1 GB	0 B
7.7 GB	15.1 GB	0 B
8.7 GB	15.1 GB	0 B
8.1 GB	15.1 GB	0 B
11.5 GB	15.1 GB	114 MB
5.2 GB	15.1 GB	0 B
9.4 GB	15.1 GB	0 B
5.1 GB	15.1 GB	0 B
7.1 GB	15.1 GB	0 B
10.1 GB	15.1 GB	0 B
9.6 GB	15.1 GB	0 B
7.4 GB	15.1 GB	1 MB

Mémoire

Num. Stores	Num. Storefiles	Storefile Size Uncompressed	Storefile Size	Index Size	Bloom Size
396	895	1.4 TB	1.4 TB	1.1 GB	7.5 GB
393	858	1.4 TB	1.4 TB	1.1 GB	6.6 GB
393	885	1.4 TB	1.4 TB	1.1 GB	7.4 GB
394	857	1.3 TB	1.3 TB	1.0 GB	6.4 GB
406	911	1.5 TB	1.5 TB	1.2 GB	7.5 GB
402	885	1.3 TB	1.3 TB	1.0 GB	6.5 GB
393	862	1.4 TB	1.4 TB	1.1 GB	7.1 GB
394	899	1.5 TB	1.5 TB	1.2 GB	7.5 GB
395	861	1.3 TB	1.3 TB	1.0 GB	6.5 GB
383	852	1.3 TB	1.3 TB	1.0 GB	6.7 GB
392	867	1.4 TB	1.4 TB	1.1 GB	6.5 GB
397	836	1.3 TB	1.3 TB	1.0 GB	6.2 GB
391	865	1.4 TB	1.4 TB	1.1 GB	6.7 GB
394	855	1.4 TB	1.4 TB	1.1 GB	7.7 GB
389	892	1.3 TB	1.3 TB	1.0 GB	6.7 GB
405	918	1.5 TB	1.5 TB	1.2 GB	7.9 GB

Stockage

Hardware:

3x Dell PowerEdge R440
- 32 Threads
- 128Go ram
- 4 disques de 4To

13x Dell PowerEdge R640
- 32 Threads
- 64Go ram
- 8 disques de 2To

HDFS:
- /data : 22To
- total /hdfs: 33To

HBase: BIC

Region Servers

Base Stats | Memory | Requests | Storefiles | Compactio

ServerName
jb-g11-14.p.infra.arkea.com,16020,1745737545371
jb-i11-05.p.infra.arkea.com,16020,1745737636381
jb-i11-06.p.infra.arkea.com,16020,1745737696580
jb-j11-07.p.infra.arkea.com,16020,1745737840266
jb-o20-31.p.infra.arkea.com,16020,1745737933231
va-g11-08.p.infra.arkea.com,16020,1745737970220
va-i11-05.p.infra.arkea.com,16020,1745738345977
va-j11-14.p.infra.arkea.com,16020,1748355694669

Total:8

8x Serveurs

Requêtes par sec: ~200 q/s

Used Heap	Max Heap	Memstore Size
9.5 GB	15.1 GB	73 MB
6.4 GB	15.1 GB	47 MB
9.1 GB	15.1 GB	67 MB
9.4 GB	15.1 GB	63 MB
7.8 GB	15.1 GB	54 MB
5.5 GB	15.1 GB	158 MB
6.5 GB	15.1 GB	54 MB
7.2 GB	15.1 GB	106 MB

Mémoire

Num. Stores	Num. Storefiles	Storefile Size Uncompressed	Storefile Size	Index Size	Bloom Size
438	643	1016.9 GB	295.2 GB	1.5 GB	5.1 GB
452	765	2.0 TB	504.6 GB	3.2 GB	9.2 GB
467	774	2.1 TB	471.5 GB	3.3 GB	9.4 GB
461	724	2.1 TB	482.2 GB	3.2 GB	9.4 GB
465	730	2.1 TB	468.9 GB	3.2 GB	8.7 GB
557	752	1.8 TB	464.3 GB	2.8 GB	8.1 GB
496	714	2.1 TB	483.4 GB	3.3 GB	9.5 GB
507	819	2.0 TB	488.3 GB	3.0 GB	8.6 GB

Stockage

Hardware BIC:

3x Dell PowerEdge R440
- 32 Threads
- 128Go ram
- 4 disques de 4To

5x Dell PowerEdge R640
- 32 Threads
- 64Go ram
- 8 disques de 2To

HDFS:
- /data : 3.6To
- total /hdfs: 43To

Add-ons Arkea

Nous avons développé 2 utilitaires Arkea autour de Hbase

- **hbase-tools** : Merge de régions (réduire le nombre de fichiers de région et compacter les données)
  Utilisé par exemple sur la BIC car les tailles de fichiers de région étaient trop petite au départ.
- **com.arkea.commons.hbase-0.5.5.jar** : Librairie utilitaire java pour simplifier :
  - la gestion des connexions et DAO
  - les FullScan Batch (redéfinition de l'input format pour règle 2 mappers par region-server au lieu d'1 mapper par region-file)
  - Unload Hdfs Orc
  - les BulkLoad

Projet Domirama

Restitution des opérations sur les comptes chèques des clients avec une capacité de recherche sur 10 ans d'historique.

Cluster	Domirama
Repos	Domirama-Root : https://gitlark.s.arkea.com/package-cav-epargne/7X04/domirama-root

	Domirama-Leaf : https://gitlark.s.arkea.com/package-cav-epargne/7X04/domirama-leaf DomiramaBatch : https://gitlark.s.arkea.com/package-cav-epargne/7X04/domiramabatch

Tables domirama

Description	'**B997X04:domirama**', { NAME => '**data**', BLOOMFILTER => 'NONE', REPLICATION_SCOPE => '1' }, {NAME => '**meta**', BLOOMFILTER => 'NONE', VERSIONS => '2', REPLICATION_SCOPE => '1'}
Key Design	Une ligne par opération • code SI (l'entité orga) • numéro de contrat (identification du compte) • binaire combinant un numéro d'opération et la date pour un ordre antichronologique
Format de stockage	Données Cobol encodées en Base64 avec un column qualifier par type de copy.
Ecriture	Préparation des données issues de la tenue de solde en PIG. Ecriture Hbase dans un programme MapReduce avec passage des opérations directement par API Hbase dans la phase de reduce.
Lecture	Lecture par l'API à l'aide de SCAN sur l'historique du client lors de sa connexion pour créer un index SOLR in-memory et un contexte de recherche.

	L'affichage des données se fait par un MultiGet des clés ramenées par l'index SOLR.
Fonctionnalités spécifiques hbase ?	• Utilisation du TTL pour purge automatique • Pas d'utilisation de la temporalité des cellules
Remarques	Un réplica complet des données est disponible également sur Elastic-search avec une profondeur de 13 mois pour l'utilisation de transactionAPI. Un projet de refonte TAILS est à l'étude pour refondre l'architecture de Domirama. Les capacités de search full-text de Dastax pourraient être un plus.

Tables domirama-budget

Description	'B997X04:domirama-budget', {TABLE_ATTRIBUTES => {MAX_FILESIZE => '2147483648'}, {NAME => 'contextmeta', BLOOMFILTER => 'NONE', TTL => '86400 SECONDS (1 DAY)', REPLICATION_SCOPE => '1' }, {NAME => 'data', BLOOMFILTER => 'NONE', REPLICATION_SCOPE => '1' }, {NAME => 'meta', BLOOMFILTER => 'NONE', VERSIONS => '2', REPLICATION_SCOPE => '1' }
Remarques	La table domirama-budget serait obsolète.

Projet Catégorisation des opérations

La catégorisation est une extension du projet domirama qui vient enrichir les opérations d'un système de catégorisation automatique et personnalisable par les clients. Pour des raisons de simplicité et de performance, le projet de catégorisation est venu ajouter une Column Family à la table domirama déjà existante en partageant le même design de clé.

Cluster	Domirama
Repos	https://gitlark.s.arkea.com/edd_technique_outil_plateforme/7x09/categorizationjar https://gitlark.s.arkea.com/edd_technique_outil_plateforme/7x09/domirama-category https://gitlark.s.arkea.com/edd_technique_outil_plateforme/7x09/categorizationapi

Tables domirama

Description	'**B997X04:domirama**', { NAME => '**category**', BLOOMFILTER => 'ROWCOL', TTL => '315619200 SECONDS (3653 DAYS)', REPLICATION_SCOPE => '1' }
Key Design	Une ligne par opération • code SI (l'entité orga) • numéro de contrat (identification du compte) • binaire combinant un numéro d'opération et la date pour un ordre antichronologique
Format de stockage	Données thrift encodées en Binaire dans une colonne + des colonnes dynamiques calquées sur certaines propriétés du pojo thrift => permet d'ajouter des filtres sur les valeurs de ces colonnes dans les Scan + Optimisation avec le BLOOMFILTER.
Ecriture	Ecriture Hbase dans un programme MapReduce en bulkLoad Ecriture par l'API pour permettre au client de corriger les résultats du moteur de catégorisation => PUT avec current_Timestamp

Lecture	Lecture Temps réel par l'API à l'aide de SCAN + value filter. Lecture batch pour des unload incrémentaux sur HDFS au format ORC (FullScan + STARTROW + STOPROW + TIMERANGE pour une fenêtre glissante et un ciblage plus précis des données à redescendre)
Fonctionnalités spécifiques hbase ?	• Utilisation du TTL pour purge automatique • Utilisation de la temporalité des cellules (le batch écrit toujours sur le même timestamp et le client sur le timestamp réel de son action donc pas d'écrasement en cas de rejeu du batch)
Remarques	

Table domirama-meta-categories

Description	**'B997X04:domirama-meta-categories'**, {NAME => 'config', REPLICATION_SCOPE => '1' }, {NAME => 'cpt_customer', VERSIONS => '50', REPLICATION_SCOPE => '1' }, {NAME => 'cpt_engine', VERSIONS => '50', REPLICATION_SCOPE => '1' }

Key Design	Plusieurs KeySpace dans la table pour des usages différents (pour éviter de créer plusieurs petites tables).
	• Acceptation de l'affichage par le client
	  ○ ACCEPT
	  ○ code efs
	  ○ no contrat
	  ○ no pse
	• Opposition categ
	  ○ OPPOSITION

	○ code efs ○ no pse ● Historique opposition ○ HISTO_OPPOSITION ○ code efs ○ no pse ● Feedbacks moteur / clients par libellé ○ ANALYZE_LABEL ○ type opération ○ sens opération ○ libellé simplifié opération ● Feedbacks moteur / clients par ICS ○ ICS_DECISION ○ type opération ○ sens opération ○ no ICS ● Règles catégorisation spécifiques client ○ CUSTOM_RULE ○ type opération ○ sens opération ○ libellé simplifié opération ● Méthode de catégorisation sur les libellé taggé salaires ○ SALARY_DECISION ○ libellé simplifié opération
Usages	Utilisée par le Batch et l'API Pour la notion de feedback, nous utilisons les **colonnes dynamiques** et les **compteurs Hbase** (incréments et décréments atomiques d'une cellule) permettant d'obtenir la distribution des catégories affectées globalement à un format particulier d'opération.
Format de stockage	Modèle colonnes plus classique avec des colonnes dynamiques pour les compteurs. Valeurs textuelles, numériques et booléenne Les colonnes varient selon les keySpace
Ecriture	Appels direct de PUT et ou INCREMENT dans le batch ou l'API

Lecture	Appels direct de GET dans le batch ou l'API
Fonctionnalités spécifiques hbase ?	• INCREMENT
Remarques	

Projet BIC

La Base d'interaction Client est un projet porté par le marketing groupe pour collecter l'intégralité des interactions entre la banque et les clients sur tous les canaux (accès au site web, passage en agence, conclusion rdv, agenda, mail, sms …).
L'objectif est de pouvoir restituer au conseiller une timeline de 2 ans d'historique des interactions avec un client ou le foyer du client.

Cluster	BIC
Repos	https://gitlark.s.arkea.com/edd_technique_outil_plateforme/3o04/bic-event https://gitlark.s.arkea.com/edd_technique_outil_plateforme/3o04/bic_backend https://gitlark.s.arkea.com/edd_technique_outil_plateforme/3o04/bic-batch https://gitlark.s.arkea.com/edd_technique_outil_plateforme/3o04/bic-unload

Table bi-client (iso bi-prospect)

Description	**'B993O02:bi-client'**, {NAME => 'A'}, {NAME => 'C', BLOOMFILTER => 'ROWCOL', VERSIONS => '2'}, {NAME => 'E', VERSIONS => '2'}, {NAME => 'M', VERSIONS => '2'}
Key Design	Une ligne par interaction client ⇔ banque • code efs (l'entité orga) • numéro de client • dateyyyyMMdd de l'interaction • cd_canal (mail, tel, rdv …)

	• idt_tech (garant de l'unicité pour MAJ)
Format de stockage	Données Json dans une colonne + des colonnes dynamiques normalisées extraites du json => permet d'ajouter des filtres sur les valeurs de ces colonnes dans les Scan + Optimisation avec le BLOOMFILTER.
Ecriture	Ecriture Temps réel embarquée dans des consumer kafka exécutés par des tomcat (bic-event) Ecriture Batch dans un programme MapReduce en bulkLoad
Lecture	Lecture Temps réel par l'API à l'aide de SCAN + value filter. Lecture batch pour des unload incrémentaux sur HDFS au format ORC (FullScan + STARTROW + STOPROW + TIMERANGE pour une fenêtre glissante et un ciblage plus précis des données à redescendre)
Fonctionnalités spécifiques hbase ?	• Utilisation du TTL pour purge automatique
Remarques	

Projet EDM

Le projet EDM est porté également par le marketing, il s'agit d'un environnement de données marketing qui améliore la connaissance client par un calcul massifs quotidien d'indicateurs. Ces indicateurs sont en partie utilisés pour l'animation de la relation commerciale.
L'aspect batch de ce traitement est complété pour certains cas d'usage par un calcul événementiel temps réel. La partie Hbase ici sert de réceptacle pour tous les événements qui ne sont pas des interactions et d'accès aux informations issues du batch pour permettre une consolidation à la volée et de repousser des événements métiers en réaction.

Cluster	BIC
Repos	https://gitlark.s.arkea.com/edd_technique_outil_plateforme/3o02/edm-event https://gitlark.s.arkea.com/edd_technique_outil_plateforme/3o02/edm-hbase

Le design d’architecture est identique à celui de la BIC et utilise Hbase de la même manière.